




Optimizador de Funciones

Documentación Técnica de Métodos de Optimización

Generado automáticamente — 2026-07-23

1. Introducción

Este documento describe, de forma completa y verificada contra la implementación real del Optimizador, los 32 métodos de optimización disponibles: 8 unidimensionales/de gradiente, 3 metaheurísticos, 6 restringidos (penalización/barrera/suma), y 14 multiobjetivo (4 técnicas clásicas del proyecto + 10 del motor de escalarización).

Cuando un usuario selecciona una combinación método-función incompatible, la aplicación bloquea la ejecución y muestra una explicación en español con métodos alternativos recomendados — ver la matriz de compatibilidad (sección 2).

2. Matriz de compatibilidad función ↔ método

Tipo de función	Compatibles	Incompatibles	Nota
1 variable, cualquier forma (continua, discontinua, no derivable)	Búsqueda Local, SA, PSO, GA	—	Los metaheurísticos y Búsqueda Local no requieren derivadas ni unimodalidad.
1 variable, unimodal en $[l_0, h_1]$	Fibonacci, Sección Áurea, Sección Dorada	Multimodal sin garantía (puede converger a un mínimo local no deseado, sin aviso)	La unimodalidad no se valida automáticamente — es responsabilidad del usuario verificarla.
1 variable o multivariable, diferenciable	Goldstein, Newton-Raphson, Grad. Conjugado, Armijo, Wolfe	Funciones con puntos no derivables en la trayectoria (Abs, sign, Piecewise no suave) — bloqueado con mensaje claro y recomendación de método alternativo	El gradiente/Hessiano se calcula simbólicamente vía SymPy; si sympy no puede derivar, el sistema traduce el error a un mensaje en español.
Multivariable, CON restricción $g(x) \leq 0$ (o $g(x) < 0$ estricta para Barreras)	Los 6 métodos MD (Penalización, Barreras, Pen. BFGS, Pes. BFGS, Pes. Nelder-Mead, Sum. BFGS)	Sin $g(x)$ definido — bloqueado con mensaje y recomendación de método sin restricción	Una sola restricción de desigualdad por corrida; no soporta igualdades ni múltiples restricciones simultáneas.
1 variable (base para $F(x)=[f_1, f_2]$ generado automáticamente)	Los 14 métodos multiobjetivo (Escalarización, MO—Bisección/Sección Dorada/Frente de Pareto/Análisis Jacobiano, y las 9 técnicas del motor de escalarización)	Funciones ya multivariable (2+ variables) — bloqueado con mensaje: «no se pudo aplicar este tipo de estudio a la expresión dada»	El sistema NO acepta un $F(x)$ multivariable directo: siempre parte de $f(x)$ de 1 variable y genera f_2 internamente.

3. Unidimensionales (1D)

Búsqueda Local

Fórmula: Evalúa $f(x)$, $f(x+p)$, $f(x-p)$; se mueve al mejor punto que mejore estrictamente; si ninguno mejora, $p \leftarrow p/2$.

Descripción: Búsqueda de patrón 1D con paso adaptativo (variante simple tipo Hooke-Jeeves), no requiere derivadas.

Requisitos matemáticos: Función evaluable en el rango $[lo,hi]$; no requiere continuidad ni derivabilidad.

Convergencia: Se detiene cuando el paso $p < \text{tolerancia}$ ($1e-5$) o tras 100 iteraciones. Lineal, sensible al paso inicial (0.1).

Ventajas: Muy simple; no necesita derivadas; robusta ante funciones no suaves.

Desventajas / limitaciones: Lenta cerca del óptimo; puede estancarse en funciones con muchos mínimos locales muy cercanos entre sí.

Cuándo usarlo: Introducción a búsqueda 1D; funciones no diferenciables o ruidosas.

Cuándo NO usarlo: Funciones multivariable (solo acepta 1 variable); cuando se necesita velocidad de convergencia alta.

Funciones compatibles: Cualquier función real de 1 variable, continua o no.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje claro).

Ejemplo: $f(x) = x^2 - 4x + 5 \rightarrow x^* \approx 2, f^* \approx 1$

Fibonacci

Fórmula: Reducción de intervalo con razones de Fibonacci: $x_{\text{new}} = a + (F_{N-2}/F_N)(b-a)$, $x_{\text{old}} = a + (F_{N-1}/F_N)(b-a)$.

Descripción: Búsqueda de sección 1D que minimiza el número de evaluaciones de f para una tolerancia objetivo dada.

Requisitos matemáticos: Función unimodal en $[lo,hi]$ (un único mínimo en el intervalo) para garantía teórica de convergencia.

Convergencia: El parámetro L (tolerancia) fija cuántos términos de Fibonacci se generan (objetivo = $(b-a)/L$); óptimamente eficiente en número de evaluaciones para funciones unimodales.

Ventajas: Mínimo número de evaluaciones de f entre los métodos de reducción de intervalo; determinístico.

Desventajas / limitaciones: Requiere unimodalidad — en funciones con varios mínimos puede converger a uno subóptimo sin avisar.

Cuándo usarlo: Funciones costosas de evaluar, unimodales, 1 variable.

Cuándo NO usarlo: Funciones multivariable o claramente multimodales en el rango elegido.

Funciones compatibles: Funciones reales de 1 variable, idealmente unimodales en $[lo,hi]$.

Funciones incompatibles: 2+ variables; L (tolerancia) ≤ 0 (bloqueado con mensaje).

Ejemplo: $f(x) = x^2 - 4x + 5, L=0.1 \rightarrow x^* \approx 2$

Sección Áurea

Fórmula: Igual que Fibonacci pero con razón fija $\tau = (\sqrt{5}-1)/2 \approx 0.618$ en vez de razones de Fibonacci calculadas.

Descripción: Golden-section search: reduce el intervalo en la razón áurea, reutilizando una evaluación de f por iteración.

Requisitos matemáticos: Función unimodal en $[lo,hi]$.

Convergencia: Se detiene cuando el intervalo $(b-a) < 1e-6$, máx. 200 iteraciones. Convergencia lineal con razón $\tau \approx 0.618$.

Ventajas: No necesita precalcular una secuencia como Fibonacci; igual de simple y robusta.

Desventajas / limitaciones: Ligeramente menos eficiente que Fibonacci en evaluaciones totales (óptimo teórico es Fibonacci).

Cuándo usarlo: Alternativa a Fibonacci cuando no se quiere fijar una tolerancia L explícita.

Cuándo NO usarlo: Funciones multivariable; funciones no unimodales.

Funciones compatibles: Funciones reales de 1 variable, unimodales en $[l_0, h_i]$.

Funciones incompatibles: 2+ variables (bloqueado con mensaje claro).

Ejemplo: $f(x) = x^2 - 4x + 5 \rightarrow x^* \approx 2$

Sección Dorada

Fórmula: Misma técnica que «Sección Áurea» (razón áurea τ); en la app es la variante usada además como sub-rutina interna de los métodos multiobjetivo escalarizados.

Descripción: Golden-section search — nombre distinto de «Sección Áurea» en el combo por motivos históricos del proyecto, mismo algoritmo base.

Requisitos matemáticos: Función unimodal en $[l_0, h_i]$.

Convergencia: Igual que Sección Áurea.

Ventajas: Igual que Sección Áurea; además es el solver interno de todas las técnicas de escalarización MO.

Desventajas / limitaciones: Igual que Sección Áurea.

Cuándo usarlo: Igual que Sección Áurea.

Cuándo NO usarlo: Funciones multivariable; no unimodales.

Funciones compatibles: Funciones reales de 1 variable, unimodales.

Funciones incompatibles: 2+ variables.

Ejemplo: $f(x) = x^2 - 4x + 5 \rightarrow x^* \approx 2$

Goldstein

Fórmula: Descenso de gradiente con condiciones de Goldstein: $f_{\text{min}} + \mu\alpha(g \cdot d) \leq f(x + \alpha d) \leq f_{\text{min}} + (1 - \mu)\alpha(g \cdot d)$, $\mu = 0.2$.

Descripción: Búsqueda de línea con doble cota (ni muy poco ni demasiado avance) sobre la dirección de máximo descenso $d = -\nabla f$.

Requisitos matemáticos: f diferenciable (gradiente vía SymPy exacto); acepta 1 o más variables.

Convergencia: Detiene cuando $\|\nabla f\| < 1e-7$; backtracking $\alpha \leftarrow 0.5\alpha$ hasta 50 intentos internos por iteración externa.

Ventajas: Evita pasos demasiado cortos (a diferencia de Armijo puro), mejorando la velocidad práctica.

Desventajas / limitaciones: Usa descenso de gradiente puro (no Newton) — convergencia más lenta que métodos de segundo orden en problemas mal condicionados.

Cuándo usarlo: Funciones diferenciables donde Armijo converge muy lento por pasos pequeños.

Cuándo NO usarlo: Funciones no diferenciables (Abs, signo, etc. en puntos no suaves).

Funciones compatibles: Funciones diferenciables, 1 o más variables.

Funciones incompatibles: Funciones no derivables en la trayectoria de búsqueda.

Ejemplo: $f(x) = x^2 - 4x + 5 \rightarrow x^* \approx 2$

Newton-Raphson

Fórmula: $x_{k+1} = x_k - (H + \text{regl})^{-1} \nabla f(x_k)$, con búsqueda de línea de respaldo si el paso no mejora f .

Descripción: Newton clásico con regularización automática del Hessiano (reg=1e-10, ×10 hasta 8 intentos) y respaldo a descenso de gradiente si sigue singular.

Requisitos matemáticos: f dos veces diferenciable (Hessiano exacto vía SymPy); 1 o más variables.

Convergencia: Cuadrática cerca del óptimo si el Hessiano es bien condicionado; detiene con $\|\nabla f\| < 1e-6$, máx. 50 iteraciones.

Ventajas: Convergencia muy rápida (cuadrática) cerca del mínimo; robusta a Hessianos casi singulares gracias a la regularización.

Desventajas / limitaciones: Cada iteración es más cara (requiere Hessiano); puede alejarse del óptimo si el punto inicial está lejos y la función no es convexa.

Cuándo usarlo: Funciones suaves, dos veces diferenciables, buen punto inicial.

Cuándo NO usarlo: Funciones no diferenciables; alta dimensión (costo del Hessiano crece como n^2).

Funciones compatibles: Funciones C^2 (dos veces diferenciables), 1 o más variables.

Funciones incompatibles: Funciones con puntos no derivables (Abs, Max no suave, etc.) en la trayectoria.

Ejemplo: $f(x) = x^2 - 4x + 5 \rightarrow x^* = 2$ en 1 iteración (cuadrática exacta)

4. Basados en gradiente/Newton (ND, sin restricción)

Grad. Conjugado

Fórmula: Fletcher-Reeves: $\beta_k = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}$; $d_{k+1} = -g_{k+1} + \beta_k \cdot d_k$. Reinicio a $-g$ cada $\max(n, 5)$ iteraciones.

Descripción: Gradiente conjugado no lineal (variante Fletcher-Reeves) con backtracking Armijo ($c_1=1e-4$) para el tamaño de paso.

Requisitos matemáticos: f diferenciable; pensado para multivariable ($n \geq 2$), aunque acepta también 1 variable.

Convergencia: Detiene con $\| \nabla f \| < 1e-6$, máx. 100 iteraciones; en problemas cuadráticos converge en a lo sumo n pasos.

Ventajas: No necesita almacenar/invertir el Hessiano — mucho más barato que Newton en alta dimensión.

Desventajas / limitaciones: Sensible a la precisión de la búsqueda de línea; en problemas no cuadráticos puede perder la propiedad de conjugación sin reinicios frecuentes.

Cuándo usarlo: Problemas multivariable de dimensión media/alta donde el Hessiano es costoso.

Cuándo NO usarlo: Funciones no diferenciables.

Funciones compatibles: Funciones diferenciables, cualquier número de variables.

Funciones incompatibles: Funciones no derivables en la trayectoria.

Ejemplo: $f(x_1, x_2) = (x_1 - 2)^2 + (x_2 - 1)^2 \rightarrow$ converge en pocos pasos

Armijo

Fórmula: Newton con paso de Armijo: $d_k = H^{-1}(-g_k)$ (o $-g_k$ si H singular); acepta α si $f(x + \alpha d) \leq f_k + \mu \cdot \alpha \cdot (g_k \cdot d_k)$, $\mu=0.6$, $\alpha \leftarrow 0.8\alpha$.

Descripción: Newton multivariable con búsqueda de línea de descenso suficiente (condición de Armijo) por retroceso.

Requisitos matemáticos: f diferenciable (gradiente y Hessiano exactos vía SymPy); acepta 1 o más variables.

Convergencia: Detiene con $\| \nabla f \| < 1e-6$, máx. 50 iteraciones; si el Hessiano es singular, detiene inmediatamente (sin respaldo a descenso puro, a diferencia de Newton-Raphson).

Ventajas: Combina la velocidad de Newton con una garantía simple de descenso suficiente; sencillo de razonar.

Desventajas / limitaciones: Sin respaldo si el Hessiano es singular (se detiene ahí, a diferencia de Newton-Raphson que sí tiene fallback); solo controla descenso, no evita pasos demasiado cortos (a diferencia de Goldstein/Wolfe).

Cuándo usarlo: Funciones diferenciables, multivariable, con Hessiano razonablemente bien condicionado.

Cuándo NO usarlo: Funciones no diferenciables (p. ej. Abs en un punto no suave) — el cálculo simbólico de la derivada falla con un error claro.

Funciones compatibles: Funciones diferenciables, cualquier número de variables.

Funciones incompatibles: Funciones no derivables (Abs/sign/Piecewise no suaves en el punto de evaluación).

Ejemplo: $f(x_1, x_2) = 2(x_1 - 3)^2 + x_1 \cdot x_2^3$, con $x_0 = [0, 0]$

Wolfe

Fórmula: Newton con condición de curvatura fuerte: $|\nabla f(x + \alpha d) \cdot d| \leq \mu \cdot |\nabla f(x) \cdot d|$, $\mu=0.6$, resuelta por bisección en $\alpha \in [0, 1]$.

Descripción: Newton multivariable con búsqueda de línea que garantiza curvatura adecuada (evita pasos demasiado cortos), vía bisección — no incluye la condición de descenso suficiente por separado (queda desacoplada de Armijo en esta implementación).

Requisitos matemáticos: f diferenciable (gradiente y Hessiano exactos); acepta 1 o más variables.

Convergencia: Bisección detiene si la condición de curvatura se cumple o el intervalo $(v-u) < 1e-7$, máx. 20 iteraciones internas.

Ventajas: Evita pasos demasiado cortos, favoreciendo avance más agresivo que Armijo puro.

Desventajas / limitaciones: Al no combinar explícitamente la condición de descenso suficiente en el mismo paso, no es un Wolfe estándar de libro de texto (fuerte/débil) sino una variante simplificada centrada en curvatura.

Cuándo usarlo: Funciones diferenciables donde Armijo converge muy lento (pasos demasiado cortos).

Cuándo NO usarlo: Funciones no diferenciables.

Funciones compatibles: Funciones diferenciables, cualquier número de variables.

Funciones incompatibles: Funciones no derivables en la trayectoria.

Ejemplo: $f(x_1, x_2) = 2(x_1 - 3)^2 + x_1 \cdot x_2^3$, con $x_0 = [0, 0]$

5. Metaheurísticos (globales, sin gradiente)

SA: Recocido Simulado

Fórmula: Enfriamiento geométrico $T \leftarrow 0.95 \cdot T$; vecino $x' = x + N(0, 0.3)$; acepta si $\Delta E < 0$, o con prob. $\exp(-\Delta E/T)$.

Descripción: Metaheurística de recocido simulado: $T_{\text{init}}=100$, $T_{\text{min}}=1e-4$, máx. 500 iteraciones, semilla fija (reproducible).

Requisitos matemáticos: Función evaluable en el rango; no requiere continuidad ni derivabilidad.

Convergencia: Probabilística/heurística, no garantizada; detiene por $T < T_{\text{min}}$ o iteraciones agotadas. Guarda el mejor punto visto, no solo el actual.

Ventajas: Escapa de mínimos locales gracias a la aceptación probabilística; robusta ante ruido y discontinuidades.

Desventajas / limitaciones: No determinística en el sentido de garantía de óptimo global; requiere ajustar el enfriamiento para problemas difíciles.

Cuándo usarlo: Funciones con muchos mínimos locales, no diferenciables, o ruidosas.

Cuándo NO usarlo: Cuando se necesita una garantía de convergencia exacta/determinística, o el presupuesto de evaluaciones es muy bajo.

Funciones compatibles: Cualquier función evaluable (continua, discontinua, no diferenciable), 1 o más variables (vía bounds).

Funciones incompatibles: Ninguna restricción estructural — el rango $[l_o, h_i]$ siempre debe ser válido ($l_o < h_i$).

Ejemplo: $f(x) = x^2 - 4x + 5$, rango $[0, 5]$

PSO: Enjambre

Fórmula: $v \leftarrow w \cdot v + c_1 \cdot r_1 \cdot (p_{\text{best}} - x) + c_2 \cdot r_2 \cdot (g_{\text{best}} - x)$, $w=0.7$, $c_1=c_2=1.5$; posición recortada a $[l_o, h_i]$.

Descripción: Particle Swarm Optimization: 30 partículas, 150 iteraciones máx. (config. de la app), semilla fija.

Requisitos matemáticos: Función evaluable en el rango $[l_o, h_i]$; no requiere derivabilidad.

Convergencia: Heurística; detiene antes si $g_{\text{best}} < 1e-10$ o la diversidad del enjambre cae por debajo de $1e-8$.

Ventajas: Buena exploración global; fácil de paralelizar conceptualmente; pocos hiperparámetros.

Desventajas / limitaciones: Puede converger prematuramente en problemas muy multimodales si $w/c_1/c_2$ no están bien ajustados; sin garantía de óptimo global.

Cuándo usarlo: Funciones multimodales, no diferenciables, con rango acotado conocido.

Cuándo NO usarlo: Cuando se requiere precisión muy alta cerca del óptimo (mejor refinar después con un método de gradiente).

Funciones compatibles: Cualquier función evaluable en un rango acotado, 1 o más variables.

Funciones incompatibles: Rango inválido ($l_o \geq h_i$, bloqueado con mensaje).

Ejemplo: $f(x) = x^2 - 4x + 5$, rango $[0, 5]$

GA: Algoritmo Genético

Fórmula: Selección por torneo ($k=3$); cruce aritmético (blend, $\alpha=0.5$); mutación gaussiana adaptativa $\sigma = 0.3(1 - g/\text{max_gen}) + 0.02$; elitismo=3.

Descripción: Algoritmo genético real-valued: población 50, 150 generaciones máx., $p_{\text{cruce}}=0.8$, $p_{\text{mutación}}=0.15$.

Requisitos matemáticos: Función evaluable en el rango $[l_o, h_i]$; no requiere derivabilidad.

Convergencia: Heurística; detiene antes si el mejor $f < 1e-10$ o la diversidad poblacional cae por debajo de $1e-9$.

Ventajas: Muy robusta ante funciones discontinuas, ruidosas o con múltiples óptimos; el elitismo evita perder buenas soluciones.

Desventajas / limitaciones: Puede requerir muchas evaluaciones de f para converger con precisión; sensible a los parámetros de mutación en problemas de alta dimensión.

Cuándo usarlo: Funciones muy irregulares, con múltiples mínimos locales similares.

Cuándo NO usarlo: Presupuesto de evaluaciones muy limitado, o se necesita precisión numérica alta cerca del óptimo.

Funciones compatibles: Cualquier función evaluable en un rango acotado, 1 o más variables.

Funciones incompatibles: Rango inválido ($lo \geq hi$).

Ejemplo: $f(x) = x^2 - 4x + 5$, rango $[0,5]$

6. Restringidos (MD) — penalización / barrera / suma

MD: Penalización (Newton)

Fórmula: $\phi(x)=f(x)+\mu \cdot \max(0,g(x))^2$, $\mu \leftarrow -10\mu$ en 3 pasadas externas ($\mu \neq 1$); resuelto con Newton propio regularizado por pasada.

Descripción: Penalización exterior cuadrática clásica para $g(x) \leq 0$, con solver interno Newton+Armijo.

Requisitos matemáticos: Requiere $g(x)$ — sin restricción, la penalización no hace nada. Interpreta $g(x) \leq 0$ como restricción de desigualdad; una sola restricción por corrida.

Convergencia: 3 pasadas externas con μ creciendo $\times 10$; cada pasada converge cuando $\|\nabla \phi\| \leq 1e-6$, máx. 60 iteraciones internas.

Ventajas: Simple de entender y depurar; no requiere punto inicial factible (a diferencia de barrera).

Desventajas / limitaciones: Mal condicionamiento numérico cuando μ crece mucho; solo admite $g(x) \leq 0$ (no igualdades, no múltiples restricciones).

Cuándo usarlo: Enseñar/demostrar penalización exterior; punto inicial infactible.

Cuándo NO usarlo: Sin restricción definida (bloqueado); restricciones de igualdad puras o múltiples restricciones simultáneas (no soportado).

Funciones compatibles: f y g diferenciables, 1+ variables, con $g(x)$ definida.

Funciones incompatibles: Sin $g(x)$ (bloqueado con mensaje y recomendación); funciones no diferenciables.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.5, 0.5]$, $f^* \approx 0.5$

MD: Barreras (Newton)

Fórmula: $\phi(x)=f(x)-(1/t) \cdot \log(-g(x))$, $t \leftarrow 10t$ en 3 pasadas ($t \neq 1$); requiere punto factible interior $g(x) < 0$.

Descripción: Método de barrera logarítmica (interior point clásico) para $g(x) < 0$ estricta, con solver interno Newton.

Requisitos matemáticos: Requiere $g(x)$. Si x_0 es infactible, la app empuja automáticamente x_0 a lo largo de $-\nabla g$ hasta 50 pasos, o aplica un jitter si no lo logra.

Convergencia: 3 pasadas con t creciendo $\times 10$; cada pasada usa línea de búsqueda que preserva factibilidad (α se reduce hasta que $g(x_{\text{new}}) < 0$), converge con $\|\nabla \phi\| \leq 1e-6$.

Ventajas: Mantiene siempre un punto factible durante toda la trayectoria — útil para visualizar cómo se acerca a la frontera de la restricción.

Desventajas / limitaciones: Requiere estrictamente $g(x) < 0$ (desigualdad estricta); numéricamente más delicado que penalización si el punto inicial está muy cerca de la frontera.

Cuándo usarlo: Cuando importa mantener factibilidad en cada iteración (interpretación tipo interior-point).

Cuándo NO usarlo: Restricciones de igualdad ($g(x)=0$ no tiene interior, la barrera no aplica); sin $g(x)$ definido.

Funciones compatibles: f y g diferenciables, 1+ variables, restricción de desigualdad estricta.

Funciones incompatibles: Sin $g(x)$; restricciones de igualdad.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.495, 0.495]$, $f^* \approx 0.51$

MD: Pen. (BFGS)

Fórmula: Misma penalización cuadrática que «MD: Penalización (Newton)» ($\phi=f+\mu \cdot \max(0,g)^2$), resuelta con BFGS (scipy) en vez de Newton propio.

Descripción: Compara el efecto del solver interno (BFGS cuasi-Newton vs. Newton exacto) manteniendo fija la técnica de restricción.

Requisitos matemáticos: Requiere $g(x)$. Igual que Penalización (Newton) en la formulación matemática.

Convergencia: 3 pasadas externas, $\mu \times 10$ cada una; BFGS converge superlinealmente sin necesitar el Hessiano exacto.

Ventajas: No requiere Hessiano simbólico (más barato por iteración que Newton en dimensión alta); BFGS suele ser más robusto ante Hessianos mal condicionados.

Desventajas / limitaciones: Convergencia superlineal, no cuadrática — puede necesitar más iteraciones que Newton cerca del óptimo.

Cuándo usarlo: Comparar el efecto del solver interno; problemas donde el Hessiano exacto es costoso o inestable.

Cuándo NO usarlo: Sin $g(x)$ (bloqueado).

Funciones compatibles: f y g diferenciables (BFGS solo necesita gradiente, aproxima el Hessiano), 1+ variables.

Funciones incompatibles: Sin $g(x)$.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.5, 0.5]$, $f^* \approx 0.5$

MD: Pes. (BFGS)

Fórmula: Penalización LINEAL de peso creciente: $\phi(x)=f(x)+w \cdot \max(0, g(x))$, $w \leftarrow 5w$ en 3 pasadas ($w_{\text{inicial}}=1$), resuelta con BFGS.

Descripción: A diferencia de la penalización cuadrática, aquí el costo de violar la restricción crece linealmente — permite comparar el efecto de la forma de la penalización, no solo del solver.

Requisitos matemáticos: Requiere $g(x)$.

Convergencia: 3 pasadas externas con w creciendo $\times 5$; BFGS converge por pasada.

Ventajas: La penalización exacta lineal puede forzar factibilidad con un peso finito (a diferencia de la cuadrática, que en teoría necesita $\mu \rightarrow \infty$); útil para contrastar ambas formas.

Desventajas / limitaciones: El término lineal introduce un punto no diferenciable en $g(x)=0$ (vía $\max(0, \cdot)$), lo que puede ralentizar la convergencia de un solver basado en gradiente como BFGS cerca de la frontera.

Cuándo usarlo: Comparar penalización lineal vs. cuadrática; funciones acotadas.

Cuándo NO usarlo: Sin $g(x)$ (bloqueado); funciones no acotadas donde un peso pequeño no basta para contener la divergencia.

Funciones compatibles: f y g diferenciables, 1+ variables, idealmente f acotada.

Funciones incompatibles: Sin $g(x)$.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.5, 0.5]$, $f^* \approx 0.5$

MD: Pes. (Nelder-Mead)

Fórmula: Misma penalización lineal que «MD: Pes. (BFGS)» ($\phi=f+w \cdot \max(0, g)$, $w \leftarrow 5w$ en 3 pasadas), resuelta con Nelder-Mead (sin derivadas, scipy).

Descripción: Compara un solver sin gradiente (simplex de Nelder-Mead) contra uno con gradiente (BFGS), con la misma técnica de restricción.

Requisitos matemáticos: Requiere $g(x)$. No necesita que f o g sean diferenciables (Nelder-Mead solo evalúa la función).

Convergencia: Más lenta y con más iteraciones que los solvers basados en gradiente; sin garantía teórica fuerte en dimensión alta.

Ventajas: Funciona incluso si f o g no son diferenciables en algún punto; no requiere gradiente ni Hessiano.

Desventajas / limitaciones: Más iteraciones/evaluaciones que BFGS; en funciones no acotadas el simplex puede explorar regiones muy alejadas (divergencia) si el peso no crece lo suficiente.

Cuándo usarlo: f o g con puntos no diferenciables; se prefiere no depender de derivadas simbólicas.

Cuándo NO usarlo: Sin $g(x)$; funciones donde ya se sabe que el gradiente exacto está disponible y es barato (mejor usar BFGS/Newton, más eficientes).

Funciones compatibles: Cualquier f y g evaluables (no necesitan ser diferenciables), 1+ variables.

Funciones incompatibles: Sin $g(x)$.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.5, 0.5]$, $f^* \approx 0.5$

MD: Sum. (BFGS)

Fórmula: Suma ingenua de una sola pasada, sin escalar peso: $h(x)=f(x)+g(x)$, resuelta con BFGS.

Descripción: Contraejemplo pedagógico: a diferencia de penalización/barrera, no hay ninguna pasada externa que aumente el costo de violar la restricción.

Requisitos matemáticos: Requiere $g(x)$; sin él, degenera en un BFGS sin restricción sobre f .

Convergencia: Una sola corrida de BFGS — mucho más rápida, pero sin ninguna garantía de que el resultado respete $g(x) \leq 0$.

Ventajas: Extremadamente simple y rápida; útil para mostrar por qué las técnicas de penalización/barrera con peso creciente son necesarias.

Desventajas / limitaciones: En general NO fuerza la factibilidad — el óptimo de $h(x)=f(x)+g(x)$ casi nunca coincide con el óptimo restringido real, y en funciones no acotadas puede diverger.

Cuándo usarlo: Únicamente con fines demostrativos/comparativos frente a los otros 5 métodos MD.

Cuándo NO usarlo: Cuando se necesita una solución que realmente respete la restricción — usar Penalización o Barrera en su lugar.

Funciones compatibles: f y g diferenciables, 1+ variables (con fines demostrativos).

Funciones incompatibles: Sin $g(x)$ (bloqueado); no debe usarse cuando se requiere factibilidad garantizada.

Ejemplo: $f=(x_1-2)^2+(x_2-1)^2$, $g=x_1+x_2-2 \rightarrow x^* \approx [1.5, 0.5]$, $f^* \approx 0.5$ (coincide aquí porque el problema es simple; no es garantía general)

7. Multiobjetivo — técnicas clásicas (Schaffer genérico)

MO — Bisección

Fórmula: Bisección sobre $\phi'(x,\alpha)=0$, donde $\phi(x,\alpha)=\alpha \cdot f_1(x)+(1-\alpha) \cdot f_2(x)$.

Descripción: Técnica clásica del proyecto (previa al motor de escalarización): resuelve la suma ponderada por bisección en vez de sección áurea.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable.

Convergencia: Bisección estándar, lineal, tolerancia configurable.

Ventajas: Determinística, fácil de trazar paso a paso para fines didácticos.

Desventajas / limitaciones: Igual limitación que suma ponderada: no cubre frentes cóncavos.

Cuándo usarlo: Fines didácticos, ver el proceso de bisección aplicado a MO.

Cuándo NO usarlo: Frente cóncavo; funciones multivariable.

Funciones compatibles: $f(x)$ de 1 variable.

Funciones incompatibles: 2+ variables.

Ejemplo: $f(x) = (x-3)^2$, $\alpha=0.5$

MO — Sección Dorada

Fórmula: Igual que Bisección pero resolviendo $\phi(x,\alpha)$ con búsqueda de sección áurea.

Descripción: Variante didáctica de suma ponderada resuelta con sección áurea en vez de bisección.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable.

Convergencia: Lineal, razón áurea.

Ventajas: Igual que Bisección; consistente con el solver usado por el resto del motor de escalarización.

Desventajas / limitaciones: Igual limitación de convexidad que suma ponderada.

Cuándo usarlo: Fines didácticos.

Cuándo NO usarlo: Frente cóncavo; funciones multivariable.

Funciones compatibles: $f(x)$ de 1 variable.

Funciones incompatibles: 2+ variables.

Ejemplo: $f(x) = (x-3)^2$, $\alpha=0.5$

MO — Frente de Pareto

Fórmula: Barrido de $\alpha \in [0,1]$ en 80 puntos; para cada α , Newton en $\phi'(x,\alpha)=0$ (hasta 100 iteraciones), registra $(f_1(x^*), f_2(x^*))$.

Descripción: Genera el frente de Pareto completo (no un solo punto) recorriendo todos los pesos α posibles.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable.

Convergencia: Newton por cada punto del barrido: cuadrática localmente; el barrido en sí es exhaustivo, no iterativo.

Ventajas: Da la visión completa del frente, no solo un punto — ideal para elegir un compromiso informado entre f_1 y f_2 .

Desventajas / limitaciones: Más costoso computacionalmente (80 resoluciones de Newton); solo aplica a f_1/f_2 generados desde una función 1D.

Cuándo usarlo: Se quiere explorar todo el frente antes de decidir un compromiso.

Cuándo NO usarlo: Cuando ya se sabe exactamente qué α se necesita (más rápido usar Suma Ponderada directamente).

Funciones compatibles: $f(x)$ de 1 variable.

Funciones incompatibles: 2+ variables.

Ejemplo: $f(x) = (x-3)^2 \rightarrow 80$ puntos del frente (f_1, f_2)

MO — Análisis Jacobiano

Fórmula: $J(x)=[f_1'(x), f_2'(x)]$ en 15 puntos de $[l_0, h_i]$; $\lambda = J_{f_2} / (J_{f_2} - J_{f_1})$; Pareto-óptimo si $0 \leq \lambda \leq 1$.

Descripción: Verifica la condición de estacionariedad de Pareto (KKT 1D) en una malla de puntos, sin resolver una optimización.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable, diferenciable.

Convergencia: No iterativo — evaluación directa del Jacobiano en 15 puntos fijos.

Ventajas: Muy rápido; permite ver directamente qué regiones del dominio son Pareto-óptimas sin resolver un problema de optimización.

Desventajas / limitaciones: Solo evalúa 15 puntos discretos — puede pasar por alto regiones Pareto-óptimas estrechas entre dos puntos de la malla.

Cuándo usarlo: Análisis exploratorio rápido de estacionariedad antes de optimizar formalmente.

Cuándo NO usarlo: Cuando se necesita el óptimo exacto, no solo un diagnóstico.

Funciones compatibles: $f(x)$ de 1 variable, diferenciable.

Funciones incompatibles: 2+ variables; funciones no diferenciables.

Ejemplo: $f(x) = (x-3)^2 \rightarrow$ tabla de 15 puntos con λ y $\blacksquare$

8. Multiobjetivo — motor de escalarización (Fase 6-8)

Escalarización (Suma Ponderada)

Fórmula: $\phi(x) = w_1 f_1(x) + w_2 f_2(x)$, pesos normalizados a partir de α : $w = [\alpha, 1-\alpha]$.

Descripción: Técnica de escalarización más simple e intuitiva; combina $F(x) = [f_1, f_2]$ en un único escalar ponderado.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app genera $f_1 = f(x)$ y $f_2 = (x - x_{\text{centro}})^2$ automáticamente); resuelto internamente con Sección Dorada.

Convergencia: La de Sección Dorada sobre $\phi(x, \alpha)$: lineal con razón áurea.

Ventajas: Simple, rápida, fácil de interpretar el efecto de α .

Desventajas / limitaciones: No captura frentes de Pareto cóncavos (zonas del frente que la suma ponderada nunca puede alcanzar, sin importar los pesos).

Cuándo usarlo: Frente de Pareto convexo; se necesita un resultado rápido con pesos intuitivos.

Cuándo NO usarlo: Frente de Pareto con regiones cóncavas — usar NBI o Restricción Normal en su lugar.

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje: «no se pudo aplicar este tipo de estudio»).

Ejemplo: $f(x) = (x-3)^2$, $\alpha = 0.5$

MO — Lexicográfico

Fórmula: $\phi = f_1 + \epsilon \cdot f_2 + \epsilon^2 \cdot f_3 + \dots$ (prioridad fija $f_1 \gg f_2$, $\epsilon \rightarrow 0$ aproxima el orden lexicográfico exacto).

Descripción: Optimiza estrictamente por orden de prioridad: primero minimiza f_1 sin importar f_2 , salvo por el término ϵ que desempata.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x) = [f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Modela preferencias jerárquicas claras («el costo importa más que el nivel de servicio, sin excepción»).

Desventajas / limitaciones: Ignora casi por completo el objetivo secundario salvo para desempatar — no da control fino sobre el balance entre objetivos.

Cuándo usarlo: Cuando un objetivo es estrictamente más importante que los demás (no hay trade-off aceptable).

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x) = [f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$

MO — Goal Programming

Fórmula: $\phi = \sum w_i \cdot |f_i(x) - \text{meta}_i|^p$ ($p=1$ por defecto).

Descripción: Define una meta aspiracional por objetivo y minimiza las desviaciones ponderadas respecto a esas metas.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x) = [f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Muy intuitivo para el usuario de negocio: «quiero costo $\leq X$ y servicio $\geq Y$ », no pesos abstractos.

Desventajas / limitaciones: El resultado depende fuertemente de qué tan realistas sean las metas elegidas; metas inalcanzables distorsionan la solución.

Cuándo usarlo: Cuando el decisor puede expresar metas concretas por objetivo (satisfacer en vez de optimizar puro).

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, metas = punto ideal

MO — ϵ -Constraint

Fórmula: $\phi = f_{\text{primario}}(x) + 1e6 \cdot \sum \max(0, f_i(x) - \epsilon_i)^2$ ($i \neq \text{primario}$).

Descripción: Deja un objetivo como función a minimizar y convierte los demás en restricciones ($f_i \leq \epsilon_i$) con penalización cuadrática.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Da control directo sobre el nivel de servicio aceptable; la interpretación es clara y la solución es fácil de justificar.

Desventajas / limitaciones: Requiere elegir ϵ con cuidado — un ϵ mal elegido puede volver el problema infactible o trivial.

Cuándo usarlo: Hay un objetivo dominante claro y los demás son restricciones de servicio.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, ϵ calculado a partir de la tabla de pagos

MO — ASF (Logro)

Fórmula: $\phi = \max_i [w_i (f_i(x) - z_i)] + \rho \cdot \sum (f_i(x) - z_i)$ (Wierzbicki, $\rho=1e-4$).

Descripción: Función de logro (Achievement Scalarizing Function): minimiza la máxima distancia ponderada a un punto de referencia z (típicamente el punto ideal).

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Puede alcanzar cualquier punto del frente de Pareto (incluso en regiones cóncavas), a diferencia de la suma ponderada.

Desventajas / limitaciones: La función $\max(\cdot)$ no es diferenciable en el punto de cambio de objetivo dominante — puede requerir más iteraciones del solver.

Cuándo usarlo: Se quiere explorar todo el frente de Pareto, incluidas regiones cóncavas.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, punto de referencia = ideal

MO — Chebyshev

Fórmula: $\phi = \max_i [w_i \cdot |f_i(x) - z_i^*|]$ (z_i^* = punto ideal).

Descripción: Distancia mínima ponderada al punto ideal en norma infinito (Chebyshev ponderado).

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Como ASF, cubre todo el frente de Pareto (cóncavo o convexo) variando los pesos.

Desventajas / limitaciones: No diferenciable en el punto de cambio de objetivo dominante; sensible a la elección del punto ideal.

Cuándo usarlo: Se quiere el punto del frente más cercano (en norma ∞) al ideal, con control de pesos.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, punto ideal calculado de la tabla de pagos

MO — NBI

Fórmula: $t(x) = ((F(x) - z) \cdot n) / \|n\|^2$; $\phi = \|(F(x) - z) - t \cdot n\|^2 - \eta \cdot t$ (Normal Boundary Intersection simplificado, $\eta=0.1$).

Descripción: Busca la intersección del frente de Pareto con una línea normal al segmento entre los puntos extremos de la tabla de pagos — genera puntos bien distribuidos en el frente.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Distribución más uniforme de puntos en el frente que la suma ponderada, incluso en frentes con curvatura variable.

Desventajas / limitaciones: Requiere la tabla de pagos (payoff table) precomputada; formulación más compleja de interpretar que suma ponderada.

Cuándo usarlo: Se necesita un muestreo bien distribuido del frente de Pareto completo.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, tabla de pagos 2×2

MO — Restricción Normal

Fórmula: $\phi = f_{\text{representativo}}(x) + 1e6 \cdot \max(0, (F(x) - z) \cdot n)^2$ (Normal Constraint).

Descripción: Variante de NBI: fija un objetivo representativo y restringe el movimiento a lo largo de la dirección normal mediante penalización.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Como NBI, produce puntos bien distribuidos; más simple de implementar/depurar que NBI puro.

Desventajas / limitaciones: Igual dependencia de la tabla de pagos; el peso de penalización (1e6) puede requerir ajuste fino en problemas mal escalados.

Cuándo usarlo: Alternativa a NBI cuando se prefiere una formulación de penalización en vez de proyección exacta.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, tabla de pagos 2×2

MO — Peso Adaptativo

Fórmula: $\phi = \sum w_i f_i(x) - \text{curvature_penalty} \cdot \min_j F(x) - p \sum_i^2$ (Adaptive Weighted Sum).

Descripción: Extiende la suma ponderada con un término que penaliza la cercanía a puntos vecinos ya encontrados, empujando hacia regiones no exploradas del frente (incluidas cóncavas).

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Puede cubrir regiones cóncavas que la suma ponderada simple no alcanza, sin la formulación $\max(\cdot)$ no diferenciable de ASF/Chebyshev.

Desventajas / limitaciones: Requiere puntos vecinos (``neighbor_points``) para que el término de curvatura tenga efecto — sin ellos, se reduce a suma ponderada simple.

Cuándo usarlo: Se está muestreando el frente iterativamente y se quiere evitar puntos redundantes.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, sin puntos vecinos $\rightarrow$ equivale a suma ponderada

MO — Punto de Referencia

Fórmula: $\phi = \max_j [w_j (f_j(x) - z_j)] + p \cdot \sum (f_j(x) - z_j)$ (misma fórmula que ASF, pero z es una aspiración libre, no necesariamente el ideal).

Descripción: Igual formulación matemática que ASF/Logro, pero pensada para que el decisor fije un punto de referencia propio (no necesariamente alcanzable), típico de métodos interactivos de decisión.

Requisitos matemáticos: $f(x)$ mono-objetivo de 1 variable (la app construye $F(x)=[f_1, f_2]$ automáticamente); resuelto con Sección Dorada.

Convergencia: La del solver interno (Sección Dorada): lineal, razón áurea.

Ventajas: Permite exploración interactiva: el decisor mueve el punto de referencia y ve cómo cambia la solución.

Desventajas / limitaciones: Misma no-diferenciabilidad que ASF; el resultado depende fuertemente del punto de referencia elegido.

Cuándo usarlo: Proceso interactivo de decisión donde el usuario ajusta su punto de referencia iterativamente.

Cuándo NO usarlo: Funciones de 2+ variables (el motor de escalarización opera sobre $F(x)=[f_1, f_2]$ generado desde una $f(x)$ de 1 variable, no sobre funciones ya multivariable).

Funciones compatibles: $f(x)$ de exactamente 1 variable.

Funciones incompatibles: Funciones de 2+ variables (bloqueado con mensaje profesional).

Ejemplo: $f(x) = (x-3)^2$, punto de referencia = $f(x_0)$

9. Funciones Matemáticas para Problemas de Inventario

EOQ Clásico (Cantidad Económica de Pedido)

Fórmula: $C(Q) = (D/Q) \cdot S + (Q/2) \cdot H$, $Q^* = \sqrt{(2DS/H)}$

Descripción: Modelo determinista clásico de Harris-Wilson: balancea el costo de ordenar ($D/Q \cdot S$, decrece con Q) contra el costo de mantener inventario ($Q/2 \cdot H$, crece con Q).

Requisitos matemáticos: Variables: $Q > 0$ (cantidad de pedido). Parámetros: D (demanda anual), S (costo fijo por pedido), H (costo de mantenimiento por unidad-año). Sin restricciones activas ni faltantes.

Convergencia: Función convexa 1D con mínimo único — cualquier método de búsqueda 1D o basado en gradiente converge al Q^* analítico.

Ventajas: Fórmula cerrada conocida para validar la convergencia numérica; problema convexo simple.

Desventajas / limitaciones: No modela faltantes, descuentos por volumen ni demanda variable.

Cuándo usarlo: Gestión de inventario con demanda y costos constantes y conocidos.

Cuándo NO usarlo: Cuando hay descuentos por volumen, faltantes permitidos o demanda incierta (usar los otros 3 modelos).

Funciones compatibles: Búsqueda Local, Fibonacci, Sección Áurea, Sección Dorada, Goldstein, Newton-Raphson, Grad. Conjugado, Armijo, Wolfe, y metaheurísticas (SA/PSO/GA).

Funciones incompatibles: Los 6 métodos MD (no hay restricción $g(x)$) y los 14 métodos multiobjetivo (una sola función de costo).

Ejemplo: $D=1000$, $S=50$, $H=2 \rightarrow Q^* \approx 223.6$, $\text{Costo}^* \approx 447.2$

EOQ con Faltantes Planeados (Backorders)

Fórmula: $C(Q,b) = (D/Q) \cdot S + H \cdot (Q-b)^2 / (2Q) + B \cdot b^2 / (2Q)$

Descripción: Extiende el EOQ clásico permitiendo un déficit controlado b , penalizado con un costo de faltante B por unidad-año.

Requisitos matemáticos: Variables: $Q > 0$, $0 \leq b \leq Q$. Parámetros: D , S , H , B (costo de faltante). 2 variables de decisión.

Convergencia: Función convexa en (Q,b) — óptimo analítico conocido para validar la solución numérica.

Ventajas: Reduce el costo total frente al EOQ clásico cuando el faltante es tolerable.

Desventajas / limitaciones: Requiere estimar B (costo de faltante), a menudo más difícil de medir que H .

Cuándo usarlo: Cuando el negocio puede tolerar backorders (pedidos pendientes) sin perder la venta.

Cuándo NO usarlo: Cuando un faltante implica pérdida de venta o cliente (usar EOQ clásico).

Funciones compatibles: Armijo, Wolfe (multivariable) y los 6 métodos MD (Penalización/Barreras/BFGS/Nelder-Mead) — todos aceptan 2 variables.

Funciones incompatibles: Búsqueda Local, Fibonacci, Sección Áurea/Dorada (estrictamente 1D) y los 14 métodos multiobjetivo.

Ejemplo: $D=1000$, $S=50$, $H=2$, $B=8 \rightarrow Q^* \approx 250.0$, $b^* \approx 50.0$

EOQ con Descuentos por Cantidad

Fórmula: $C_i(Q) = (D/Q) \cdot S + (Q/2) \cdot (r \cdot p_i) + D \cdot p_i$, por tramo i

Descripción: Función de costo por tramos: el precio unitario p_i (y por tanto el costo de mantenimiento $r \cdot p_i$) cambia según el rango de cantidad pedida.

Requisitos matemáticos: Variable: $Q > 0$. Parámetros: D , S , tasa de mantenimiento r (fracción del precio), y ≥ 2 tramos (cantidad_mínima, precio_unitario) ordenados.

Convergencia: No derivable en los puntos de quiebre entre tramos — requiere métodos que no dependan de gradiente.

Ventajas: Modela descuentos reales por volumen de compra.

Desventajas / limitaciones: Función no suave; los métodos basados en gradiente pueden fallar o dar resultados incorrectos cerca de los quiebres.

Cuándo usarlo: Cuando el proveedor ofrece precios escalonados por volumen.

Cuándo NO usarlo: Cuando el precio unitario es fijo (usar EOQ clásico).

Funciones compatibles: Búsqueda Local y metaheurísticas (SA: Recocido Simulado, PSO: Enjambre, GA: Algoritmo Genético).

Funciones incompatibles: Newton-Raphson, Goldstein, Armijo, Wolfe, Grad. Conjugado (requieren derivadas continuas); Fibonacci y Sección Áurea/Dorada (asumen unimodalidad, que los saltos de precio pueden romper); los 6 métodos MD y los 14 multiobjetivo.

Ejemplo: $D=1000$, $S=50$, $r=0.2$, tramos= $[(0,10),(100,9),(500,8)] \rightarrow$ compara costo total entre tramos factibles

Revisión Periódica / Punto de Reorden (ROP) Probabilístico

Fórmula: $ROP = \mu_L + z \cdot \sigma_L$, $\mu_L = d \cdot L$, $\sigma_L = \sigma_d \cdot \sqrt{L}$, $\Phi(z) = \text{nivel_servicio}$

Descripción: Calcula el punto de reorden bajo demanda probabilística: stock de seguridad = $z \cdot \sigma_L$, donde z es la inversa de la normal estándar evaluada en el nivel de servicio deseado. Q^* se sigue optimizando con la función de costo del EOQ clásico.

Requisitos matemáticos: Parámetros: d (demanda diaria promedio), σ_d (desviación estándar diaria), L (lead time en días), nivel de servicio $\in (0,1)$, más D , S , H para Q^* .

Convergencia: El ROP se calcula analíticamente (no requiere optimizador); Q^* converge igual que en EOQ clásico.

Ventajas: Incorpora incertidumbre de la demanda con un nivel de servicio objetivo explícito.

Desventajas / limitaciones: Asume demanda normalmente distribuida durante el lead time.

Cuándo usarlo: Cuando la demanda es variable y se requiere un nivel de servicio (probabilidad de no quiebre de stock) explícito.

Cuándo NO usarlo: Cuando la demanda es determinista y constante (usar EOQ clásico).

Funciones compatibles: Mismos métodos que EOQ clásico para optimizar Q (el ROP en sí es analítico, no pasa por el optimizador).

Funciones incompatibles: Los 6 métodos MD y los 14 multiobjetivo (misma razón que EOQ clásico).

Ejemplo: $d=20$, $\sigma_d=5$, $L=7$, nivel_servicio=0.95 $\rightarrow z \approx 1.645$, $ROP \approx 171.9$